10. Encoding/teckenkodning

Jag ?lskar r?ksm?rg?s.

Om encoding/teckenkodning

- Encoding handlar om hur tecken kodas och lagras i filer.
- Tecken representeras av bytes (en eller flera).
- en byte består av 8 bitar
- en bit är 1 eller 0

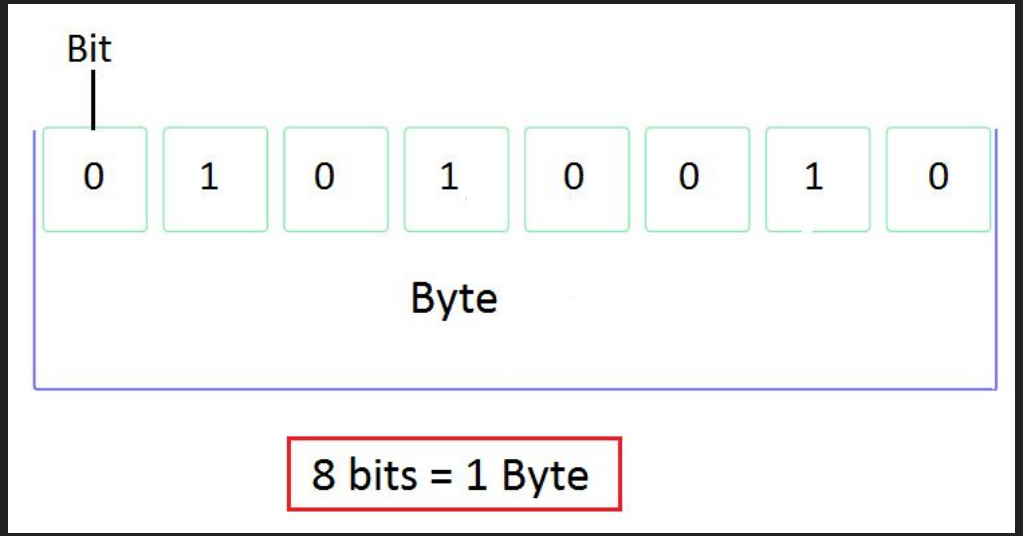

Om encoding - Ascii

- Användes i Internets början.
- Använde 1 byte, men nyttjade bara 7 bitar.
- Kunde koda 128 tecken.

Decimal - Binary - Octal - Hex – ASCII Conversion Chart

Decimal	Binary	Octal	Hex	ASCII	Decimal	Binary	Octal	Hex	ASCII	Decimal	Binary	Octal	Hex	ASCII	Decimal	Binary	Octal	Hex	ASCII
0	00000000	000	00	NUL	32	00100000	040	20	SP	64	01000000	100	40	@	96	01100000	140	60	`
1	00000001	001	01	SOH	33	00100001	041	21	!	65	01000001	101	41	A	97	01100001	141	61	a
2	00000010	002	02	STX	34	00100010	042	22	"	66	01000010	102	42	B	98	01100010	142	62	b
3	00000011	003	03	ETX	35	00100011	043	23	#	67	01000011	103	43	C	99	01100011	143	63	c
4	00000100	004	04	EOT	36	00100100	044	24	$	68	01000100	104	44	D	100	01100100	144	64	d
5	00000101	005	05	ENQ	37	00100101	045	25	%	69	01000101	105	45	E	101	01100101	145	65	e
6	00000110	006	06	ACK	38	00100110	046	26	&	70	01000110	106	46	F	102	01100110	146	66	f
7	00000111	007	07	BEL	39	00100111	047	27	'	71	01000111	107	47	G	103	01100111	147	67	g
8	00001000	010	08	BS	40	00101000	050	28	(	72	01001000	110	48	H	104	01101000	150	68	h
9	00001001	011	09	HT	41	00101001	051	29	)	73	01001001	111	49	I	105	01101001	151	69	i
10	00001010	012	0A	LF	42	00101010	052	2A	*	74	01001010	112	4A	J	106	01101010	152	6A	j
11	00001011	013	0B	VT	43	00101011	053	2B	+	75	01001011	113	4B	K	107	01101011	153	6B	k
12	00001100	014	0C	FF	44	00101100	054	2C	,	76	01001100	114	4C	L	108	01101100	154	6C	l
13	00001101	015	0D	CR	45	00101101	055	2D	-	77	01001101	115	4D	M	109	01101101	155	6D	m
14	00001110	016	0E	SO	46	00101110	056	2E	.	78	01001110	116	4E	N	110	01101110	156	6E	n
15	00001111	017	0F	SI	47	00101111	057	2F	/	79	01001111	117	4F	O	111	01101111	157	6F	o
16	00010000	020	10	DLE	48	00110000	060	30	0	80	01010000	120	50	P	112	01110000	160	70	p
17	00010001	021	11	DC1	49	00110001	061	31	1	81	01010001	121	51	Q	113	01110001	161	71	q
18	00010010	022	12	DC2	50	00110010	062	32	2	82	01010010	122	52	R	114	01110010	162	72	r
19	00010011	023	13	DC3	51	00110011	063	33	3	83	01010011	123	53	S	115	01110011	163	73	s
20	00010100	024	14	DC4	52	00110100	064	34	4	84	01010100	124	54	T	116	01110100	164	74	t
21	00010101	025	15	NAK	53	00110101	065	35	5	85	01010101	125	55	U	117	01110101	165	75	u
22	00010110	026	16	SYN	54	00110110	066	36	6	86	01010110	126	56	V	118	01110110	166	76	v
23	00010111	027	17	ETB	55	00110111	067	37	7	87	01010111	127	57	W	119	01110111	167	77	w
24	00011000	030	18	CAN	56	00111000	070	38	8	88	01011000	130	58	X	120	01111000	170	78	x
25	00011001	031	19	EM	57	00111001	071	39	9	89	01011001	131	59	Y	121	01111001	171	79	y
26	00011010	032	1A	SUB	58	00111010	072	3A	:	90	01011010	132	5A	Z	122	01111010	172	7A	z
27	00011011	033	1B	ESC	59	00111011	073	3B	;	91	01011011	133	5B	[	123	01111011	173	7B	{
28	00011100	034	1C	FS	60	00111100	074	3C	<	92	01011100	134	5C	\	124	01111100	174	7C	|
29	00011101	035	1D	GS	61	00111101	075	3D	=	93	01011101	135	5D	]	125	01111101	175	7D	}
30	00011110	036	1E	RS	62	00111110	076	3E	>	94	01011110	136	5E	^	126	01111110	176	7E	~
31	00011111	037	1F	US	63	00111111	077	3F	?	95	01011111	137	5F	_	127	01111111	177	7F	DEL

Om encoding - ISO 8859-1 (Latin 1)

- Använde 8 bitar.
- Kunde koda 191 tecken.
- Stödjer bl.a. hela svenska alfabetet.

ISO-8859-1																
	x0	x1	x2	x3	x4	x5	x6	x7	x8	x9	xA	xB	xC	xD	xE	xF
0x	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	HT	LF	VT	FF	CR	SO	SI
1x	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	IS4	IS3	IS2	IS1
2x	SP	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3x	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4x	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5x	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6x	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7x	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	DEL
8x	PAD	HOP	BPH	NBH	IND	NEL	SSA	ESA	HTS	HTJ	VTS	PLD	PLU	RI	SS2	SS3
9x	DCS	PU1	PU2	STS	CCH	MW	SPA	EPA	SOS	SGCI	SCI	CSI	ST	OSC	PM	APC
Ax	NBSP	¡	¢	£	¤	¥	¦	§	¨	©	ª	«	¬	SHY	®	¯
Bx	°	±	²	³	´	µ	¶	·	¸	¹	º	»	¼	½	¾	¿
Cx	À	Á	Â	Ã	Ä	Å	Æ	Ç	È	É	Ê	Ë	Ì	Í	Î	Ï
Dx	Ð	Ñ	Ò	Ó	Ô	Õ	Ö	×	Ø	Ù	Ú	Û	Ü	Ý	Þ	ß
Ex	à	á	â	ã	ä	å	æ	ç	è	é	ê	ë	ì	í	î	ï
Fx	ð	ñ	ò	ó	ô	õ	ö	÷	ø	ù	ú	û	ü	ý	þ	ÿ

Om encoding - Unicode

- Branschstandard för hur text ska lagras digitalt.
- Unicode-konsortiet styr (bl.a. Google, Apple, Microsoft…)
- Stödjer alla skriftspråk, även kinesiska (ca 70 000 tecken)
- Kodas på olika sätt
  - UTF-8
  - UTF-16
  - UTF-32
- Stödjer emojis! 👍💯

https://www.w3schools.com/html/html_charset.asp

Vilka encodings har använts?

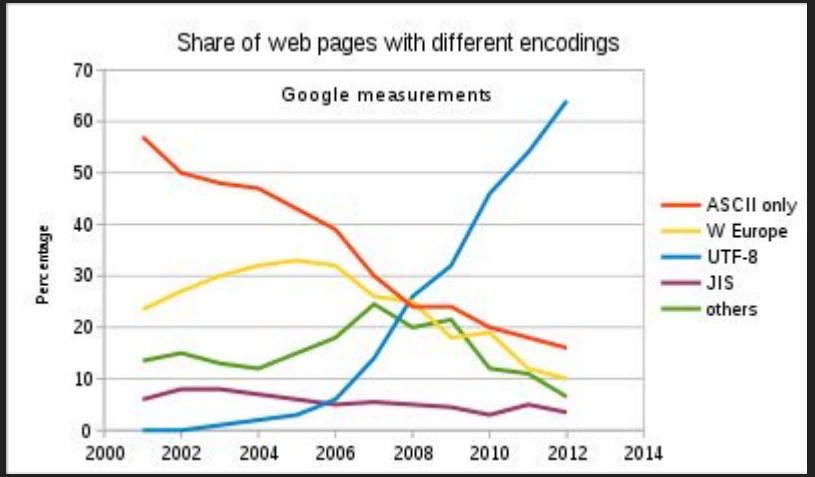

Källa: https://en.wikipedia.org/wiki/UTF-8

Vilken encoding används nu?

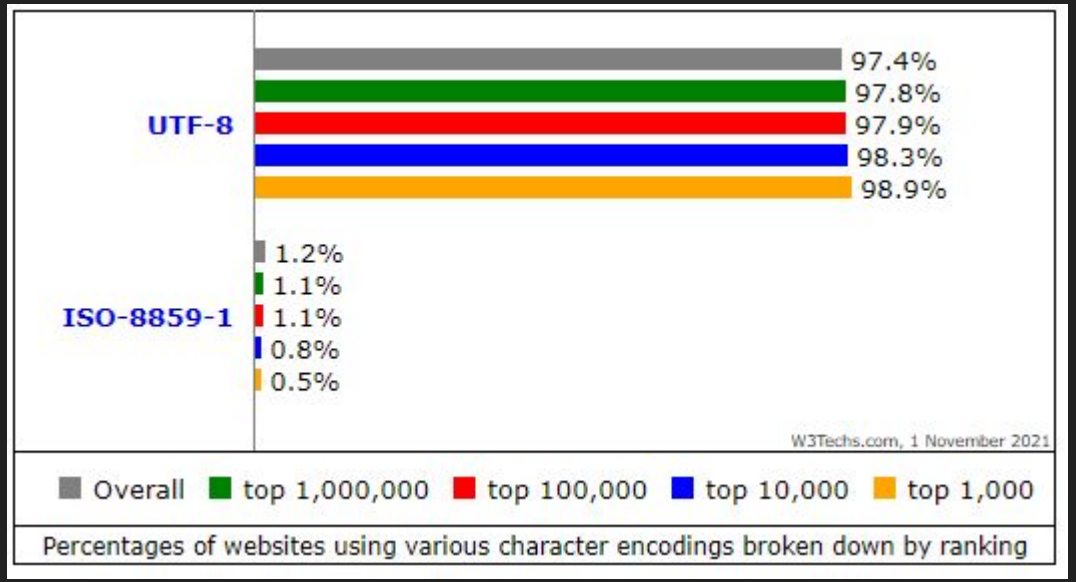

Källa: https://w3techs.com/technologies/cross/character_encoding/ranking

HTML-entiteter: specialtecken

Tecken som ingår i HTML måste kodas på ett speciellt sätt om de ska visas i webbläsaren.

Det görs enligt mönstret `&entity_name;`

Ex: “Hakar”

<	less than	<
>	greater than	>

https://www.w3schools.com/html/html_entities.asp

HTML-entiteter: specialtecken

En hel del andra tecken och symboler kan representeras med HTML-entiteter. (Se länk nedan för exempel.)

Men använder man UTF-8 löser man det mesta utan dem!

https://www.w3schools.com/html/html_symbols.asp

DEMO

Uppgift 1 - kodning av tecken (använd penna och papper)

Ni är två datorer som kodar tecken på olika sätt.

Uppgift 1 - kodning av tecken (använd penna och papper)

Arbeta i par med att koda tecken.

1. En av er använder ASCII för att koda (ersätt varje bokstav med dess ***decimala*** representation) och den andra avkodar med ISO-8859-1 (ersätter decimal representation med bokstav).
   Ascii-tabell
   ISO-8859-1-tabell
   Exempel: `Ordet “Mat” blir 77 97 116 enligt ASCII.`
   Ni ska koda ordet “Frukost?”.
2. Vänd på det hela. Den som har ISO-8859-1 kodar nu ordet “Smörgås”. Den som har ASCII kodar av meddelandet.
3. Hur fungerar de båda alternativen? Varför? Försök förklara för varandra.

Uppgift 1 - scenariot

1. Kodar “Frukost?”
2. Avkodar “Smörgås” från ISO-8859-1

1. Kodar “Smörgås”
2. Avkodar “Frukost?” från Ascii

Uppgift 2 - testa charset och encoding

Skapa en sida i VSCode.
Se till att `<meta charset="UTF-8" />` finns i <head>.
Se till att filen är sparad med UTF-8.
Skriv något i filen med emojis, åäö och andra konstiga tecken.
Titta på sidan i webbläsaren. Ser den bra ut?
Ändra till `<meta charset="ISO-8859-1" />` i <head>. Vad händer?

Hur kan du undvika problem med kodning av tecken?